UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM
PRODI S1 SAINS DATA

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Analisis Pola Pembelian Konsumen Menggunakan Algoritma Apriori dan FP-Growth pada Dataset Retail Market Basket

Adisti Eka Nabila (24031554119), Umi Imro'atus Sholekhah (24031554150),
Maris Al Sabina Azzuhra (24031554188)
Dosen Pengampu Mata Kuliah : Ulfa Siti Nuraini, S.Stat., M.Stat., dan Siska Puspitaningsih, S.Kom., M.Kom.
Kelas 2024B
Program Studi Sains Data, Universitas Negeri Surabaya

Abstrak. Perkembangan teknologi informasi pada sektor retail menyebabkan jumlah data transaksi terus meningkat, namun data tersebut sering kali belum dimanfaatkan secara optimal untuk memahami pola pembelian konsumen. Penelitian ini bertujuan untuk menganalisis pola pembelian konsumen menggunakan metode Frequent Pattern Mining dengan algoritma Apriori dan FP-Growth pada dataset Retail Market Basket Transactions. Analisis dilakukan untuk menemukan frequent itemset dan association rules berdasarkan nilai support, confidence, dan lift sehingga dapat diketahui hubungan antar produk yang sering dibeli secara bersamaan.
Tahapan penelitian meliputi preprocessing data, exploratory data analysis (EDA), transformasi data menggunakan one-hot encoding, penerapan algoritma Apriori dan FP-Growth, serta evaluasi performa kedua algoritma berdasarkan jumlah pola dan efisiensi waktu komputasi. Hasil penelitian diharapkan mampu menghasilkan insight bisnis berupa strategi bundling produk, cross-selling, dan penataan produk pada sektor retail. Selain itu, penelitian ini juga bertujuan menentukan algoritma yang paling optimal dalam analisis pola pembelian konsumen.
Kata kunci: Frequent Pattern Mining, Apriori, FP-Growth, Association Rule, Market Basket

BAB 1 Pendahuluan

1.1 Latar Belakang

Perkembangan teknologi informasi dan digitalisasi pada sektor retail menyebabkan jumlah data transaksi penjualan terus meningkat. Setiap transaksi pembelian konsumen sebenarnya menyimpan informasi penting mengenai kebiasaan dan pola pembelian pelanggan. Namun, pada banyak perusahaan retail, data transaksi tersebut masih belum dimanfaatkan secara optimal dan hanya digunakan sebagai arsip penjualan. Akibatnya, strategi pemasaran dan penjualan sering kali dilakukan berdasarkan perkiraan sehingga kurang efektif dan kurang tepat sasaran. Kondisi ini menunjukkan pentingnya pemanfaatan data transaksi untuk mendukung pengambilan keputusan bisnis berbasis data. Salah satu pendekatan yang dapat digunakan adalah market basket analysis, yaitu teknik analisis yang digunakan untuk menemukan hubungan antar produk yang sering dibeli secara bersamaan oleh konsumen. Informasi tersebut dapat dimanfaatkan untuk mendukung strategi bundling produk, cross-selling, promosi, serta penataan produk pada rak penjualan. Analisis pola pembelian pada penelitian ini tidak difokuskan pada sistem rekomendasi produk secara personal, melainkan pada pencarian keterkaitan antar produk dalam transaksi konsumen untuk menghasilkan insight strategi pemasaran retail.

Metode yang umum digunakan dalam *market basket analysis* adalah *Frequent Pattern Mining* dengan *algoritma Apriori dan FP-Growth. Algoritma Apriori* bekerja dengan membentuk kandidat *itemset* secara berulang untuk menemukan *frequent itemset* berdasarkan nilai *minimum support*. Namun, *algoritma* ini memiliki kelemahan karena

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

membutuhkan proses *scanning database* berulang sehingga kurang efisien pada *dataset* berukuran besar (Xie, 2021). Sebagai pengembangannya, *algoritma FP-Growth* menggunakan struktur *FP-Tree* sehingga proses pencarian *frequent itemset* menjadi lebih efisien tanpa candidate generation berulang (Usmani et al., 2021). Beberapa penelitian terdahulu menunjukkan bahwa *algoritma Apriori* dan *FP-Growth* mampu menghasilkan *association rule* yang bermanfaat dalam analisis pola pembelian konsumen.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk menganalisis pola pembelian konsumen menggunakan *algoritma Apriori* dan *FP-Growth* pada *dataset Retail Market Basket Transactions*. Sebelum proses mining dilakukan, data transaksi akan melalui tahap preprocessing untuk mempersiapkan data agar sesuai dengan kebutuhan analisis. Hasil penelitian diharapkan dapat menghasilkan *frequent itemset* dan *association rules* yang bermanfaat dalam mendukung strategi pemasaran dan penjualan pada sektor retail. Selain itu, insight yang diperoleh dari hasil analisis diharapkan dapat membantu perusahaan dalam menentukan strategi *cross-selling, bundling produk,* serta penataan produk pada rak penjualan berdasarkan pola pembelian konsumen.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, penelitian ini dirumuskan dalam beberapa permasalahan berikut:

1. Bagaimana menemukan pola pembelian konsumen dari data transaksi retail?
2. Bagaimana penerapan metode *Frequent Pattern Mining* menggunakan *algoritma Apriori* dan *FP-Growth?*
3. Algoritma mana yang lebih efisien dalam menghasilkan *frequent itemset*?

1.3 Tujuan

Penelitian ini bertujuan untuk menganalisis pola pembelian konsumen melalui data transaksi retail menggunakan metode *Frequent Pattern Mining.* Adapun tujuan penelitian ini adalah sebagai berikut:

1. Menemukan pola asosiasi antar produk dalam data transaksi retail.
2. Menerapkan *algoritma Apriori* dan *FP-Growth* dalam analisis market basket.
3. Membandingkan efisiensi dan performa kedua *algoritma* tersebut.

1.4 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat dalam memahami pola pembelian konsumen serta mendukung strategi bisnis berbasis data. Adapun manfaat penelitian ini adalah sebagai berikut:

1. Memberikan insight pola pembelian konsumen.
2. Membantu strategi bisnis seperti bundling produk, cross-selling, dan penataan produk.
3. Menjadi referensi dalam penggunaan metode Frequent Pattern Mining untuk analisis data transaksi.

BAB 2 Metodologi Penelitian

2.1 Penjelasan Dataset

Dataset yang digunakan adalah *Retail Market Basket Transactions Dataset* yang tersedia secara publik melalui Kaggle dan dapat diakses pada tautan: https://www.kaggle.com/datasets/wasiqaliyasir/retail-market-basket-transactions-dataset. Dataset ini terdiri dari 7.501 transaksi dengan sekitar 120 item yang merepresentasikan berbagai produk yang dibeli oleh pelanggan. Setiap baris data menunjukkan satu transaksi yang berisi kumpulan item yang dibeli secara bersamaan.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Dataset ini tidak mencantumkan periode waktu tertentu sehingga analisis tidak berfokus pada aspek temporal.

Dalam penelitian ini, data difokuskan pada bentuk transaksi untuk menemukan pola keterkaitan antar item menggunakan metode *Frequent Pattern Mining.* Proses *preprocessing* dan transformasi data dilakukan dengan mengubah data transaksi ke dalam bentuk list transaksi dan *matriks biner (one-hot encoding)* agar sesuai dengan kebutuhan *algoritma Apriori* dan *FP-Growth.* Hasil analisis diharapkan dapat menghasilkan informasi berupa pola pembelian konsumen yang dapat dimanfaatkan dalam strategi *bisnis retail,* seperti *bundling produk*, *cross-selling,* dan penataan produk pada rak penjualan. Dataset ini dipilih karena memiliki karakteristik transaksi market basket yang sesuai untuk penerapan metode Frequent Pattern Mining menggunakan algoritma Apriori dan FP-Growth dalam menemukan pola asosiasi antar produk.

2.2 Variabel Penelitian

Variabel penelitian yang digunakan dalam studi ini disesuaikan dengan karakteristik dataset transaksi retail yang berbentuk market basket. Dataset tidak memiliki atribut Transaction ID secara eksplisit, namun setiap baris data merepresentasikan satu transaksi sehingga dapat dianggap sebagai identitas transaksi secara implisit. Oleh karena itu, variabel yang digunakan terdiri dari Transaction ID (TID) yang dibentuk berdasarkan urutan baris data, serta Item sebagai kumpulan produk dalam setiap transaksi.

Tabel 1. Variabel Penelitian

Simbol	Nama Variabel	Tipe Data	Deskripsi
TID	Transaction ID	Integer	Identitas transaksi yang dibentuk berdasarkan urutan baris data
Item	Produk	string	Kumpulan item atau produk yang dibeli dalam satu transaksi

2.3 Penelitian Terdahulu

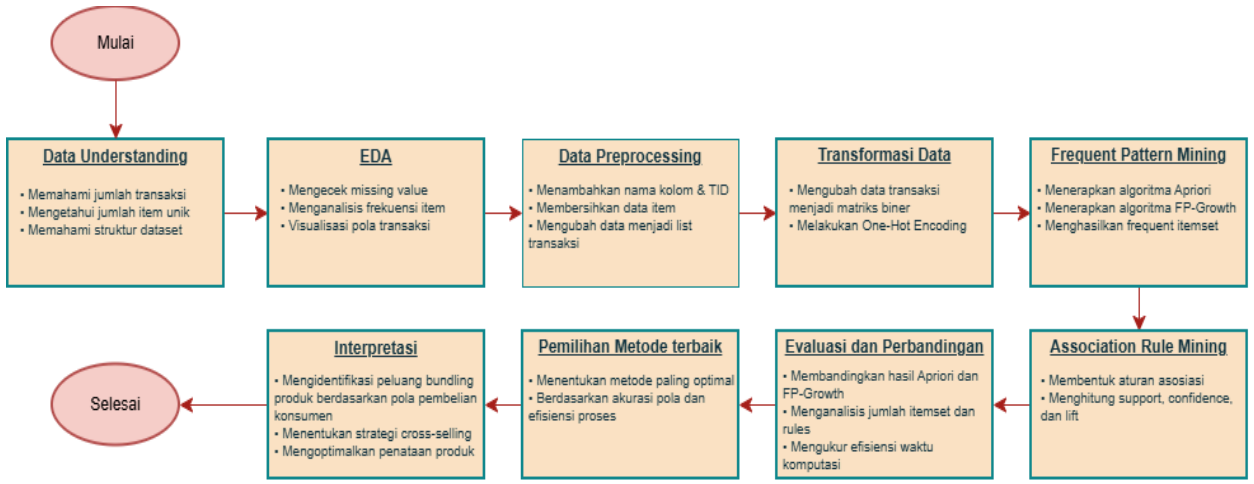
Penelitian yang dilakukan oleh Hery Hery dan Andree E. Widjaja berjudul *"Analysis of Apriori and FP-Growth Algorithms for Market Basket Insights: A Case Study of The Bread Basket Bakery Sales"* (2024) membahas penerapan *algoritma Apriori* dan *FP-Growth* dalam analisis market basket pada data penjualan bakery. Penelitian tersebut menunjukkan bahwa *algoritma FP-Growth* memiliki efisiensi waktu komputasi yang lebih baik dibandingkan *algoritma Apriori* dalam menemukan *frequent itemset* dan *association rules.* Hasil penelitian dimanfaatkan untuk menemukan pola pembelian konsumen yang dapat mendukung strategi bisnis retail seperti bundling produk dan pengambilan keputusan pemasaran (Hery & Widjaja, 2024).

Penelitian pendukung yang dilakukan oleh Aisyah Pinky Marshanda dkk berjudul *"Perbandingan Efisiensi Metode Apriori dan FP Growth"* (2024) membahas penerapan *algoritma Apriori* dan *FP-Growth* untuk menganalisis pola pembelian konsumen pada data transaksi retail. Penelitian tersebut berfokus pada perbandingan efisiensi kedua algoritma dalam proses *Frequent Pattern Mining* dan menunjukkan bahwa *algoritma FP-Growth* lebih efisien dibandingkan Apriori karena tidak memerlukan proses candidate generation secara berulang. Penelitian ini mendukung penelitian yang dilakukan karena memiliki kesamaan dalam penggunaan *algoritma Apriori* dan *FP-Growth* untuk menemukan pola pembelian konsumen berdasarkan data transaksi retail (Marshanda et al., 2024).

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Meskipun beberapa penelitian terdahulu menunjukkan bahwa FP-Growth cenderung lebih efisien dibandingkan Apriori, hasil penelitian ini menunjukkan bahwa pada dataset Retail Market Basket Transactions, algoritma Apriori memiliki runtime yang lebih cepat dengan hasil frequent itemset dan association rules yang sama.

2.4 Tahapan Penelitian



2.5 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dan struktur dataset sebelum proses preprocessing dan mining dilakukan. Tahap ini bertujuan untuk memperoleh gambaran awal mengenai pola transaksi dan distribusi item pada dataset retail. Hasil EDA digunakan sebagai dasar dalam menentukan proses preprocessing dan parameter pada tahap Frequent Pattern Mining.

Tahapan EDA yang dilakukan meliputi:

1. Pengecekan Dimensi Dataset
   Dilakukan untuk mengetahui jumlah transaksi dan jumlah kolom item pada dataset.
2. Identifikasi Missing Value
   Dilakukan untuk mengetahui distribusi nilai kosong pada setiap transaksi. Missing value pada dataset menunjukkan tidak adanya item tambahan dalam transaksi.
3. Perhitungan Jumlah Item Unik
   Dilakukan untuk mengetahui banyaknya variasi produk yang terdapat dalam dataset.
4. Analisis Frekuensi Item
   Dilakukan untuk mengetahui item yang paling sering muncul atau dibeli oleh konsumen.
5. Visualisasi Top Item
   Frekuensi item divisualisasikan menggunakan barplot untuk mempermudah interpretasi item yang paling dominan.
6. Distribusi Jumlah Item per Transaksi
   Dilakukan untuk mengetahui pola jumlah pembelian item pada setiap transaksi konsumen.
7. Deteksi Outlier Jumlah Item per Transaksi
   Dilakukan menggunakan metode Interquartile Range (IQR) dan visualisasi boxplot

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

untuk mengidentifikasi transaksi dengan jumlah item yang berada di luar pola umum. Pada penelitian ini, outlier tidak langsung dihapus karena transaksi dengan jumlah item tinggi masih dapat merepresentasikan perilaku pembelian konsumen yang valid dan berpotensi memberikan pola asosiasi penting.

2.6 *Preprocessing Data*

Tahap *preprocessing* dilakukan untuk menyiapkan data agar sesuai untuk analisis menggunakan metode *Frequent Pattern Mining.* Adapun langkah-langkah yang akan dilakukan adalah sebagai berikut:

1. Penambahan Nama Kolom
   Nama kolom ditambahkan menjadi Item1 hingga Item20 untuk mempermudah identifikasi item pada setiap transaksi.
2. Pembentukan Transaction ID (TID)
   Transaction ID ditambahkan berdasarkan urutan baris data agar setiap transaksi memiliki identitas unik.
3. Penanganan Missing Value
   Missing value tidak dihapus karena menunjukkan tidak adanya item tambahan dalam transaksi. Nilai kosong hanya diabaikan saat proses pembentukan transaksi.
4. Pembersihan Nama Item
   Nama item diseragamkan dengan mengubah teks menjadi lowercase dan menghapus spasi berlebih untuk menghindari perbedaan penulisan item.
5. Pemeriksaan Duplikasi Transaksi
   Pemeriksaan dilakukan untuk memastikan apakah terdapat transaksi duplikat yang dapat mempengaruhi hasil analisis. Jika terdapat duplikat, transaksi tersebut tidak dihapus karena dalam *market basket analysis* transaksi dengan kombinasi item yang sama masih dapat merepresentasikan pembelian valid dari konsumen yang berbeda.
6. Transformasi ke Bentuk List Transaksi
   Setiap transaksi diubah ke dalam bentuk list item agar sesuai dengan kebutuhan algoritma Frequent Pattern Mining.

2.7 Transformasi Data

Pada tahap *transformasi data, dataset* transaksi retail yang semula berbentuk daftar item pada setiap transaksi diubah menjadi format yang lebih terstruktur agar dapat diproses oleh *algoritma Frequent Pattern Mining.* Proses ini dilakukan dengan mengonversi data ke dalam bentuk list transaksi dan matriks biner menggunakan teknik *one-hot encoding,* sehingga setiap item direpresentasikan secara eksplisit dalam setiap transaksi (Fabrianto et al., 2021). Transformasi ini sangat penting karena *algoritma Apriori* dan *FP-Growth* membutuhkan representasi data yang sistematis untuk menghitung frekuensi kemunculan item secara akurat.

Hasil one-hot encoding menghasilkan matriks biner berukuran 7501 × 119, di mana nilai 1 menunjukkan bahwa suatu item dibeli dalam transaksi, sedangkan nilai 0 menunjukkan bahwa item tersebut tidak dibeli. Representasi ini mempermudah proses perhitungan support, confidence, dan pembentukan frequent itemset serta association rules pada tahap selanjutnya (Xie, 2021). Dengan demikian, transformasi data menjadi tahap krusial yang menentukan keberhasilan analisis pola pembelian konsumen karena data telah berada dalam format terstruktur, konsisten, dan sesuai dengan kebutuhan algoritma Apriori maupun FP-Growth.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

2.8 Frequent Pattern Mining

Frequent Pattern Mining merupakan teknik dalam data mining yang digunakan untuk menemukan pola berupa kombinasi item yang sering muncul dalam suatu dataset transaksi. Pola yang ditemukan disebut sebagai *frequent itemsets*, yaitu kumpulan item yang memiliki frekuensi kemunculan di atas nilai minimum support yang telah ditentukan. Teknik ini banyak digunakan dalam analisis data transaksi retail untuk mengidentifikasi pola pembelian konsumen, sehingga perusahaan dapat memahami perilaku pelanggan dan mengoptimalkan strategi pemasaran (Hery & Widjaja, 2024). Dua algoritma yang umum digunakan dalam *Frequent Pattern Mining* adalah *Apriori* dan *FP-Growth*. Kedua algoritma ini memiliki pendekatan yang berbeda dalam menemukan *frequent itemsets*, di mana *Apriori* menggunakan metode pembangkitan kandidat secara iteratif, sedangkan *FP-Growth* memanfaatkan struktur *FP-Tree* yang lebih efisien karena tidak memerlukan pembangkitan kandidat secara berulang (Usmani et al., 2021).

Pada penelitian ini dilakukan proses tuning minimum support menggunakan beberapa nilai, yaitu 0,005; 0,01; 0,015; 0,02; 0,03; dan 0,05, dengan tuning minimum confidence serta aturan asosiasi yang dipilih memiliki nilai lift > 1. Evaluasi dilakukan berdasarkan jumlah *frequent itemset*, jumlah *association rules*, rata-rata nilai lift, dan waktu komputasi untuk menentukan parameter yang paling sesuai. Berdasarkan hasil pengujian, dipilih minimum support sebesar 0,01 karena menghasilkan keseimbangan antara jumlah pola yang terbentuk, kualitas aturan asosiasi, dan efisiensi proses. *Frequent itemset* yang diperoleh dari algoritma *Apriori* dan *FP-Growth* kemudian diurutkan berdasarkan nilai support dan divisualisasikan untuk mempermudah interpretasi pola pembelian konsumen.

2.9 Algoritma Apriori

Algoritma Apriori merupakan salah satu metode dalam Frequent Pattern Mining yang digunakan untuk menemukan frequent itemset berdasarkan nilai minimum support. Algoritma ini bekerja dengan memanfaatkan prinsip bahwa setiap subset dari itemset yang sering muncul juga harus bersifat frequent. Proses pencarian pola dilakukan secara iteratif dengan membentuk kandidat itemset dan menghitung nilai support untuk menentukan apakah kombinasi item memenuhi ambang minimum yang telah ditentukan (Xie, 2021). Namun, algoritma Apriori memerlukan proses scanning database secara berulang sehingga efisiensi komputasinya dapat menurun ketika jumlah transaksi dan kombinasi item semakin besar.

Dalam penelitian ini, algoritma Apriori digunakan untuk menganalisis pola pembelian konsumen pada dataset retail serta membentuk association rules berdasarkan nilai support dan confidence. Penelitian ini menggunakan minimum support sebesar 0,01 dan minimum confidence sebesar 0,3 untuk memperoleh frequent itemset dan association rules yang relevan. Pada runtime algoritma Apriori dihitung menggunakan fungsi time pada Python untuk mengetahui waktu komputasi yang dibutuhkan dalam menghasilkan frequent itemset. Hasil dari algoritma Apriori kemudian dibandingkan dengan algoritma FP-Growth untuk mengevaluasi efektivitas dan efisiensi kedua metode dalam menemukan pola pembelian pada Market Basket Analysis (Fabrianto et al., 2021).

2.10 Algoritma FP-Growth

Algoritma *FP-Growth* merupakan metode dalam *Frequent Pattern Mining* yang digunakan untuk menemukan *frequent itemset* tanpa proses *candidate generation* secara berulang. Algoritma ini bekerja dengan membangun struktur *FP-Tree* (*Frequent Pattern*

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Tree) untuk menyimpan data transaksi secara ringkas, sehingga dapat mengurangi proses *scanning database* (Usmani et al., 2021). Penelitian Handoko et al. (2023) juga menunjukkan bahwa algoritma *FP-Growth* dapat digunakan untuk menemukan pola pembelian melalui pembentukan struktur *FP-Tree* tanpa melakukan proses pembangkitan kandidat itemset secara berulang.

Dalam penelitian ini, algoritma *FP-Growth* digunakan untuk menganalisis pola pembelian konsumen pada dataset *retail* serta membentuk *association rules* berdasarkan nilai *support* dan *confidence*. Penelitian ini menggunakan minimum *support* sebesar 0,01 dan minimum *confidence* sebesar 0,3, serta menghitung *runtime* menggunakan fungsi *time* pada Python untuk mengetahui efisiensi komputasi. Hasil dari algoritma *FP-Growth* kemudian dibandingkan dengan algoritma Apriori karena performa komputasi dapat berbeda bergantung pada karakteristik dataset, jumlah transaksi, dan struktur data yang digunakan (Hery & Widjaja, 2024)

2.11 Association Rule

Association rule merupakan teknik dalam data mining yang digunakan untuk menemukan hubungan antar item dalam bentuk aturan. Aturan ini dinyatakan dalam bentuk implikasi, yaitu jika suatu item atau kombinasi item muncul, maka item lain cenderung ikut muncul. Parameter utama yang digunakan meliputi support, confidence, dan lift, di mana support menunjukkan frekuensi kemunculan itemset, confidence menunjukkan tingkat kepercayaan terhadap aturan, dan lift mengukur kekuatan hubungan antar item dibandingkan dengan kejadian acak (Rai et al., 2022).

Association rule mining banyak digunakan dalam market basket analysis untuk memahami pola pembelian konsumen berdasarkan hubungan antar produk yang sering dibeli secara bersamaan. Informasi yang diperoleh dari association rule dapat dimanfaatkan dalam strategi bisnis retail seperti bundling produk, cross-selling, penataan produk pada rak penjualan, serta pengambilan keputusan pemasaran berbasis data (Fabrianto et al., 2021).

Pada penelitian ini, aturan asosiasi dibentuk berdasarkan frequent itemset yang dihasilkan oleh algoritma Apriori dan FP-Growth. Tuning minimum confidence dilakukan menggunakan nilai 0,2; 0,3; 0,4; dan 0,5. Aturan asosiasi yang dipertahankan adalah aturan dengan nilai lift > 1. Hasil association rules kemudian diurutkan berdasarkan nilai lift untuk menentukan rule dengan hubungan paling kuat antar item. Dengan demikian, association rule yang dihasilkan diharapkan mampu memberikan insight mengenai pola pembelian konsumen pada dataset Retail Market Basket Transactions.

2.12 Metrik Evaluasi

Metrik evaluasi dalam penelitian ini digunakan untuk mengukur kualitas dan kekuatan hubungan dari aturan asosiasi yang dihasilkan oleh *algoritma Apriori* dan *FP-Growth.* Parameter utama yang digunakan adalah *support, confidence, dan lift,* di mana *support* menunjukkan tingkat kemunculan suatu *itemset* dalam *dataset, confidence* mengukur probabilitas kemunculan item konsekuen berdasarkan *item antecedent,* sedangkan *lift* digunakan untuk mengetahui kekuatan hubungan antar item dan menentukan apakah hubungan tersebut bersifat positif atau tidak (Rai et al., 2022). Ketiga metrik ini digunakan untuk menentukan aturan asosiasi yang relevan dan signifikan. Selain itu, penelitian ini juga membandingkan efisiensi waktu komputasi dari kedua algoritma untuk menentukan metode yang paling optimal dalam menemukan pola pembelian konsumen pada dataset retail (Hery & Widjaja, 2024).

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

2.13 Evaluasi dan Perbandingan Algoritma

Evaluasi dilakukan untuk membandingkan performa algoritma Apriori dan *FP-Growth* dalam proses *Market Basket Analysis* pada dataset transaksi *retail*. Aspek yang digunakan dalam evaluasi meliputi jumlah *frequent itemset*, jumlah *association rules*, *average confidence*, *average lift*, dan *runtime*. Nilai *lift* digunakan untuk mengukur kekuatan hubungan antar item dalam *association rules*, sedangkan *runtime* digunakan untuk mengevaluasi efisiensi proses komputasi algoritma (Fabrianto et al., 2021).

Perbandingan dilakukan karena Apriori menggunakan proses *candidate generation* dan *scanning database* secara berulang, sedangkan *FP-Growth* menggunakan struktur *FP-Tree* untuk mengurangi proses pembentukan kandidat itemset (Usmani et al., 2021). Penelitian Vivian et al. (2026) juga menggunakan pendekatan perbandingan algoritma Apriori dan *FP-Growth* dalam analisis pola transaksi untuk mengetahui metode yang lebih optimal berdasarkan pola yang terbentuk dan efisiensi proses komputasi. Oleh karena itu, penelitian ini membandingkan kedua algoritma berdasarkan jumlah *frequent itemset*, jumlah *association rules*, nilai *support*, *confidence*, *lift*, serta *runtime*.

2.14 Pemilihan Metode Terbaik

Pemilihan metode terbaik dilakukan dengan membandingkan algoritma Apriori dan FP-Growth dalam proses pencarian frequent itemset dan association rules pada dataset Retail Market Basket Transactions. Perbandingan dilakukan berdasarkan jumlah frequent itemset, jumlah association rules, average confidence, average lift, dan runtime dari masing-masing algoritma (Usmani et al., 2021).

Pada penelitian ini, kedua algoritma digunakan dengan parameter minimum support sebesar 0,01 dan minimum confidence sebesar 0,3 untuk menghasilkan aturan asosiasi yang relevan. Selain kualitas aturan asosiasi yang dihasilkan, efisiensi waktu komputasi juga menjadi salah satu aspek penting dalam menentukan metode yang paling optimal.

Algoritma Apriori bekerja dengan membentuk kandidat itemset secara bertahap berdasarkan prinsip frequent itemset, sedangkan FP-Growth menggunakan struktur FP-Tree untuk menemukan pola asosiasi tanpa proses candidate generation berulang. Meskipun FP-Growth pada umumnya dikenal lebih efisien untuk dataset berukuran besar, performa kedua algoritma dapat berbeda tergantung karakteristik dataset yang digunakan (Hery & Widjaja, 2024).

Berdasarkan proses evaluasi dan perbandingan yang dilakukan, metode terbaik dipilih berdasarkan kemampuan algoritma dalam menghasilkan association rules yang relevan serta efisiensi runtime pada dataset penelitian. Dengan demikian, proses pemilihan metode terbaik diharapkan dapat menentukan algoritma yang paling optimal untuk analisis pola pembelian konsumen pada dataset retail.

2.15 Analisis dan Interpretasi Hasil

Tahap analisis dan interpretasi hasil dilakukan untuk mengubah hasil *association rule mining* menjadi informasi yang dapat diterapkan dalam konteks bisnis retail. Pola hubungan antar item yang diperoleh akan dianalisis untuk menghasilkan strategi *bundling produk* dimana penggabungan produk yang sering dibeli bersama, *cross-selling* yaitu merekomendasi produk tambahan kepada konsumen, serta *product placement* atau penataan produk berdasarkan kedekatan hubungan antar item. Sebagai contoh implementasi, apabila ditemukan aturan asosiasi seperti konsumen yang membeli *spaghetti* cenderung juga membeli *ground beef* , maka produk dapat ditawarkan dalam

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

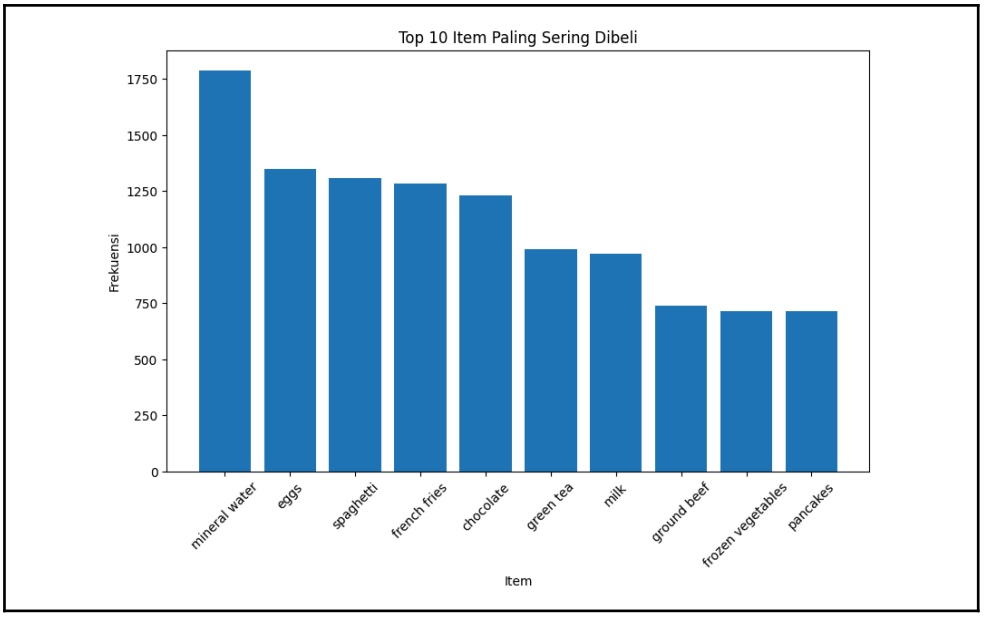
bentuk paket promosi, direkomendasikan saat pembelian, atau ditempatkan pada area rak yang berdekatan untuk meningkatkan peluang pembelian dan efektivitas strategi penjualan (Hery & Widjaja, 2024).

BAB 3 Hasil dan Pembahasan

3.1 Karakteristik Data

Pada tahap karakteristik data dilakukan analisis awal terhadap dataset Retail Market Basket Transactions untuk memahami struktur dan distribusi data sebelum proses Frequent Pattern Mining dilakukan. Dataset terdiri dari 7.501 transaksi dengan 20 kolom item, di mana setiap baris merepresentasikan satu transaksi pembelian konsumen. Hasil pengecekan menunjukkan bahwa seluruh kolom bertipe object karena berisi data kategori berupa nama produk. Selain itu, ditemukan sebanyak 120.657 missing value yang menunjukkan tidak adanya item tambahan dalam transaksi sehingga tidak dianggap sebagai kesalahan data. Untuk mempermudah proses analisis, nama kolom diubah menjadi Item1 hingga Item20. Setelah dilakukan pembersihan data, diperoleh sebanyak 119 item unik pada seluruh transaksi.

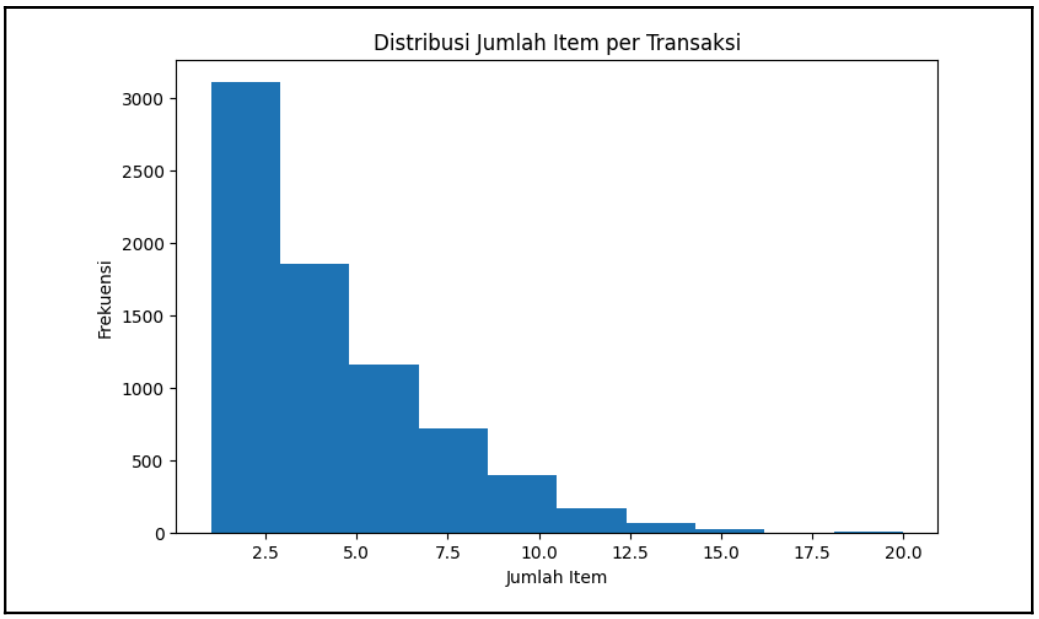
Analisis frekuensi item menunjukkan bahwa produk yang paling sering dibeli adalah mineral water sebanyak 1.788 transaksi, diikuti oleh eggs sebanyak 1.348 transaksi, spaghetti sebanyak 1.306 transaksi, dan french fries sebanyak 1.282 transaksi. Hasil visualisasi pada Gambar 1 menunjukkan bahwa mineral water menjadi item dengan frekuensi pembelian tertinggi dibandingkan item lainnya. Kondisi ini menunjukkan bahwa produk kebutuhan sehari-hari dan makanan cepat saji memiliki tingkat pembelian yang relatif tinggi pada dataset retail.



Gambar 1. Visualisasi Top 10 Item Paling Sering Dibeli

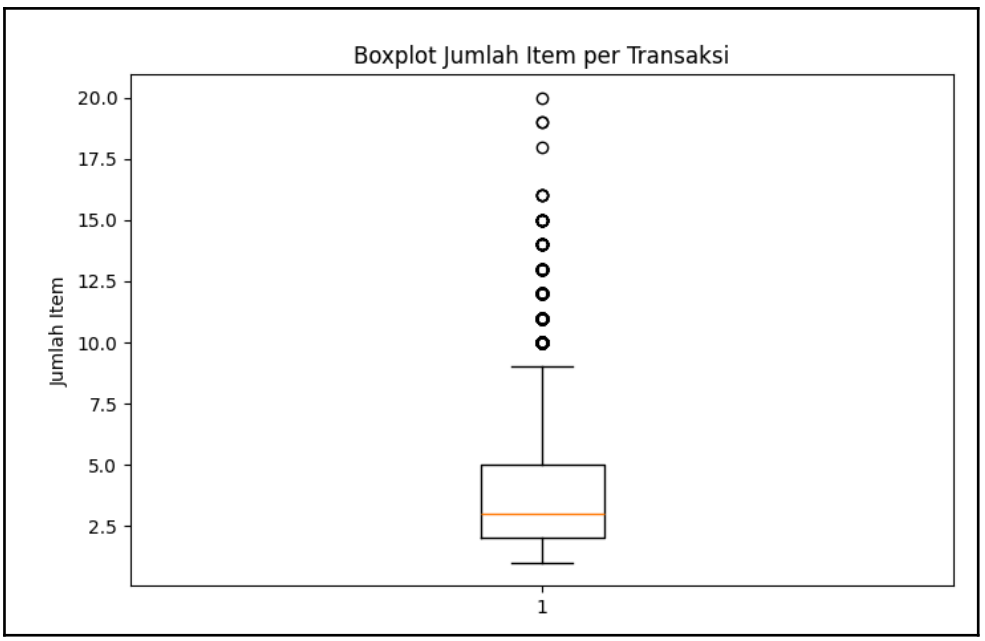
Selain itu, histogram distribusi jumlah item per transaksi pada Gambar 1 menunjukkan bahwa sebagian besar konsumen membeli item dalam jumlah sedikit, yaitu sekitar 1 hingga 5 item pada setiap transaksi. Semakin banyak jumlah item dalam transaksi, frekuensinya semakin menurun. Hasil karakteristik data ini memberikan gambaran awal mengenai pola pembelian konsumen dan menjadi dasar dalam proses preprocessing serta penentuan parameter pada tahap *Frequent Pattern Mining*.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id



Gambar 2. Distribusi Jumlah Item per Transaksi

Analisis lanjutan menggunakan boxplot dan metode Interquartile Range (IQR) menunjukkan adanya beberapa transaksi dengan jumlah item yang lebih tinggi dibandingkan mayoritas transaksi lainnya (outlier). Namun, outlier tersebut tidak dihapus karena masih merepresentasikan transaksi pembelian yang valid dan berpotensi memberikan informasi penting dalam pembentukan frequent itemset serta association rules. Oleh karena itu, outlier hanya digunakan sebagai bagian dari analisis karakteristik data tanpa dilakukan penghapusan.



Gambar 3. Boxplot Jumlah Item per Transaksi

Secara keseluruhan, hasil karakteristik data memberikan gambaran mengenai struktur transaksi, distribusi item, pola jumlah pembelian, serta variasi perilaku konsumen sebagai dasar dalam proses preprocessing dan Frequent Pattern Mining. Informasi karakteristik data ini juga digunakan dalam menentukan parameter minimum support dan minimum confidence yang sesuai pada tahap analisis association rule.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

3.2 Hasil *Preprocessing*

Pada tahap preprocessing, dataset telah melalui proses penambahan nama kolom, pembentukan *Transaction ID*, pembersihan nama item, pemeriksaan transaksi duplikat, serta transformasi data ke dalam bentuk *list* transaksi dan matriks biner. Nama kolom Item1 hingga Item20 ditambahkan untuk mempermudah identifikasi item pada setiap transaksi, sedangkan Transaction ID (TID) ditambahkan berdasarkan urutan data agar setiap transaksi memiliki identitas unik. Setiap nama item kemudian dibersihkan dengan mengubah teks menjadi lowercase dan menghapus spasi berlebih untuk menghindari perbedaan penulisan item yang dapat memengaruhi hasil analisis.

Pemeriksaan duplikasi transaksi menunjukkan bahwa terdapat 2.325 transaksi duplikat, tetapi tidak dihapus karena transaksi dengan kombinasi item yang sama masih dapat merepresentasikan perilaku pembelian konsumen yang valid dalam market basket analysis. Selain itu, missing value tidak dihapus karena menunjukkan tidak adanya item tambahan dalam transaksi dan bukan merupakan kesalahan data. Nilai kosong hanya diabaikan pada saat proses pembentukan transaksi sehingga tidak memengaruhi proses Frequent Pattern Mining.

Data transaksi kemudian diubah ke dalam bentuk list transaksi, di mana setiap transaksi berisi daftar item yang dibeli oleh konsumen. Setelah itu, dilakukan proses transformasi data menggunakan teknik one-hot encoding sehingga data berubah menjadi matriks biner berukuran 7501 × 119. Pada matriks tersebut, nilai 1 menunjukkan bahwa suatu item dibeli dalam transaksi, sedangkan nilai 0 menunjukkan item tidak dibeli.

Tabel 2. Hasil Preprocessing Data

Tahapan Preprocessing	Hasil
Penambahan nama kolom	Kolom berhasil diubah menjadi Item1 hingga Item20
Penambahan Transaction ID	TID berhasil ditambahkan berdasarkan urutan transaksi
Penanganan missing value	Missing value dipertahankan karena menunjukkan tidak adanya item tambahan
Pembersihan nama item	Seluruh item berhasil diubah menjadi lowercase dan spasi berlebih dihapus
Pemeriksaan transaksi serupa	Ditemukan 2.325 transaksi dengan kombinasi item yang sama dan tetap dipertahankan karena masih valid dalam *market basket analysis*.
Pembentukan list transaksi	Data berhasil diubah menjadi list transaksi
Transformasi one-hot encoding	Data berhasil ditransformasikan menjadi matriks biner berukuran 7501 × 119

Berdasarkan Tabel 2. Hasil Preprocessing *Data* Hasil preprocessing menunjukkan bahwa dataset telah berhasil dibersihkan dan ditransformasikan ke dalam format yang

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

lebih terstruktur dan sesuai untuk proses Frequent Pattern Mining. Proses preprocessing ini membantu memastikan konsistensi data sehingga algoritma Apriori dan FP-Growth dapat melakukan pembentukan frequent itemset dan association rules secara lebih optimal (Fabrianto et al., 2021).

3.3 Hasil Frequent Pattern Mining

Pada tahap *Frequent Pattern Mining*, dilakukan proses pencarian *frequent itemset* menggunakan algoritma *Apriori* dan *FP-Growth* berdasarkan nilai minimum support yang telah ditentukan. Kedua algoritma digunakan untuk mengidentifikasi kombinasi item yang sering muncul secara bersamaan dalam dataset transaksi retail sehingga dapat menggambarkan pola pembelian konsumen (Xie, 2021).

3.3.1 Hasil Tuning Minimum Support

Proses tuning minimum support dilakukan untuk menentukan nilai support yang paling optimal dalam menghasilkan *frequent itemset* dan *association rules*. Pengujian dilakukan menggunakan beberapa nilai minimum support, yaitu 0,005; 0,01; 0,015; 0,02; 0,03; dan 0,05. Hasil tuning ditampilkan pada Tabel 3 yang berisi nilai minimum support, jumlah minimal transaksi, jumlah *frequent itemset*, jumlah *association rules*, *average lift*, dan runtime proses komputasi pada algoritma *Apriori* dan *FP-Growth*. Nilai minimal transaksi menunjukkan jumlah minimum kemunculan item dalam dataset agar dapat dianggap sebagai *frequent itemset*. Sementara itu, average lift digunakan untuk mengukur kekuatan hubungan antar item, dan runtime menunjukkan lama waktu komputasi yang dibutuhkan oleh masing-masing algoritma.

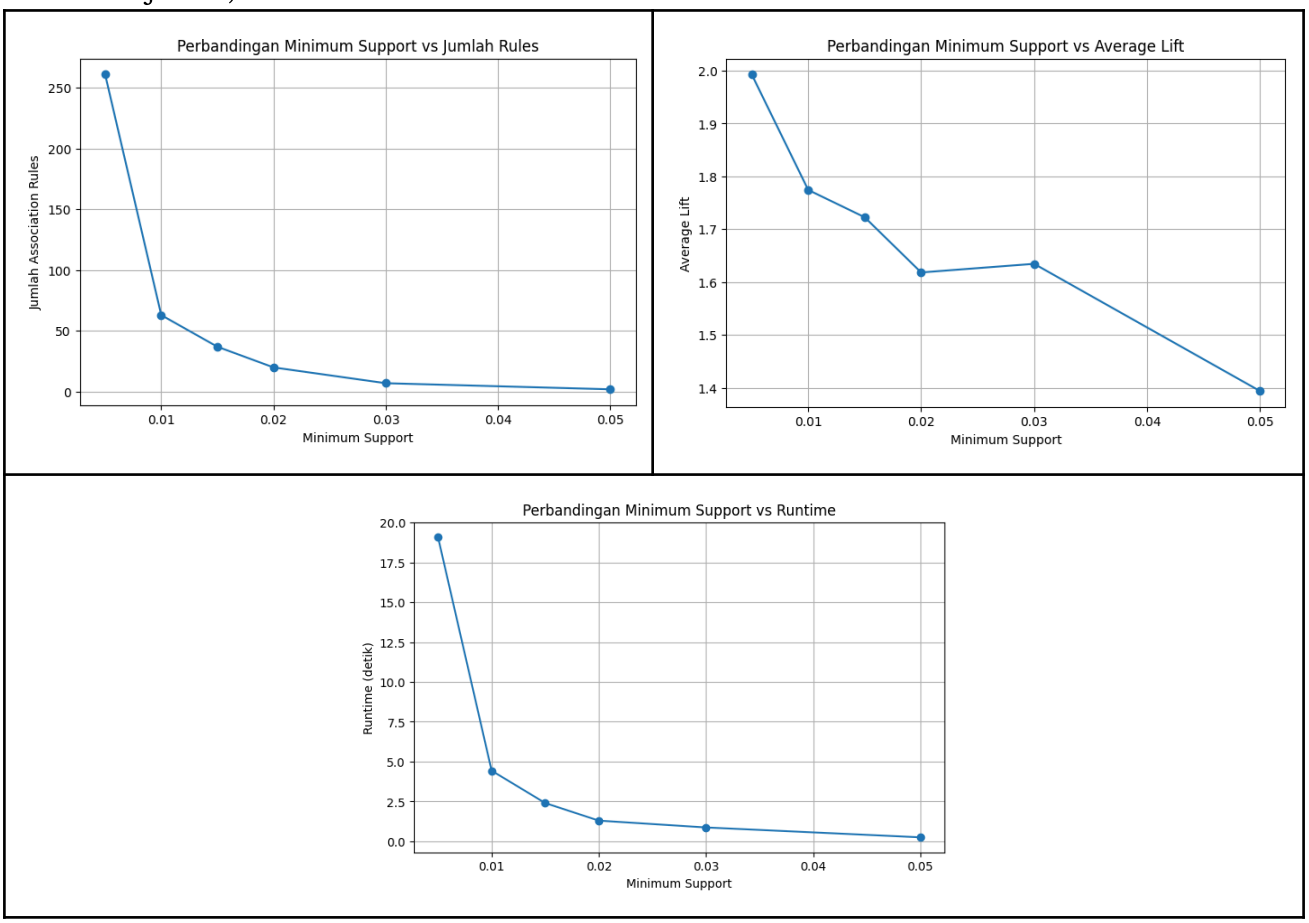
Tabel 3. Hasil Tuning Minimum Support

Minimum Support	Minimal Transaksi	Apriori Frequent Itemset	Apriori Rules	Apriori Avg Lift	Apriori Runtime (detik)	FP Frequent Itemset	FP Rules	FP Avg Lift	FP Runtime (detik)
0,005	38	725	261	1,99	2,70	725	261	1,99	17,68
0,010	75	257	63	1,77	0,45	257	63	1,77	5,46
0,015	113	153	37	1,72	0,32	153	37	1,72	3,54
0,020	150	103	20	1,61	0,16	103	20	1,61	1,32
0,030	225	54	7	1,63	0,06	54	7	1,63	0,49
0,050	375	28	2	1,39	0,03	28	2	1,39	0,15

Berdasarkan Tabel 3, semakin kecil nilai minimum support maka jumlah *frequent itemset* dan *association rules* yang dihasilkan semakin banyak. Pada *minimum support* 0,005 diperoleh 725 *frequent itemset* dan 261 *association rules*, sedangkan pada *minimum support* 0,05 hanya diperoleh 28 *frequent itemset* dan 2 *association rules*. Pada minimum support 0,01 diperoleh 257 *frequent itemset* dan 63 *association rules* dengan *average lift* sebesar 1,77 sehingga masih mampu menghasilkan pola asosiasi yang cukup baik dengan runtime yang relatif efisien. Selain itu, runtime proses komputasi juga menjadi lebih cepat

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

seiring meningkatnya *minimum support*, di mana runtime *FP-Growth* menurun dari 19,07 detik menjadi 0,25 detik.



Gambar 4.Grafik Hasil Tuning

Berdasarkan grafik hasil tuning, terlihat bahwa jumlah association rules mengalami penurunan signifikan ketika nilai *minimum support* meningkat. Grafik *average lift* menunjukkan bahwa kualitas hubungan antar item cenderung menurun pada support yang lebih besar. Selain itu, grafik runtime menunjukkan bahwa semakin besar *minimum support* maka proses komputasi menjadi lebih cepat. Oleh karena itu, *minimum support* sebesar 0,01 dipilih sebagai parameter terbaik karena menghasilkan jumlah rules yang cukup banyak, nilai average lift yang masih baik, serta runtime yang relatif efisien dibandingkan support yang lebih rendah.

3.3.2 Hasil Frequent Itemset Apriori

Penerapan algoritma *Apriori* menggunakan *minimum support* sebesar 0,01 menghasilkan beberapa *frequent itemset* yang memiliki frekuensi kemunculan tinggi pada data transaksi retail. *Frequent itemset* tersebut menunjukkan item yang paling sering dibeli oleh konsumen dalam satu transaksi. Hasil *frequent itemset Apriori* dapat dilihat pada Tabel 4 berikut.

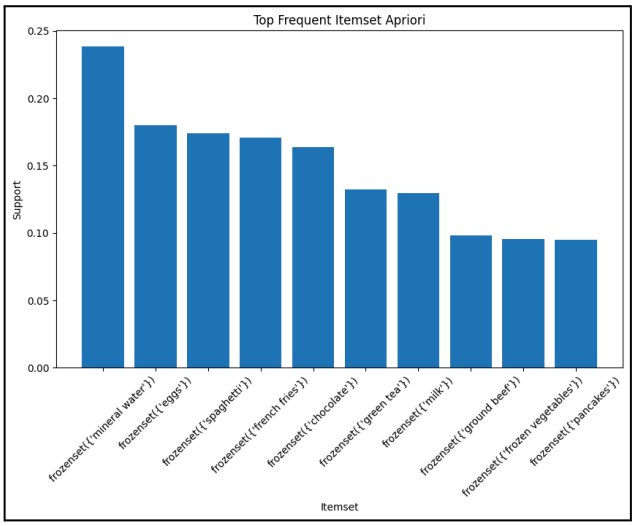
Tabel 4. Top 10 Hasil Frequent Itemset Apriori dengan Minimum Support 0,01

No	Support	Itemsets
1	0.238368	frozenset({'mineral water'})
2	0.179709	frozenset({'eggs'})

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

3	0.174110	frozenset({'spaghetti'})
4	0.170911	frozenset({'french fries'})
5	0.163845	frozenset({'chocolate'})
6	0.132116	frozenset({'green tea'})
7	0.129583	frozenset({'milk'})
8	0.098254	frozenset({'ground beef'})
9	0.095321	frozenset({'frozen vegetables'})
10	0.095054	frozenset({'pancakes'})

Berdasarkan Tabel 4, item *mineral water* memiliki nilai support tertinggi sebesar 0,238368, yang menunjukkan bahwa item tersebut paling sering muncul dalam transaksi konsumen. Selain itu, item seperti *eggs*, *spaghetti*, dan *french fries* juga memiliki frekuensi pembelian yang tinggi sehingga berpotensi menjadi produk utama dalam strategi pemasaran dan bundling produk.



Gambar 5.Top 10 Frequent Itemset Apriori

3.3.3 Hasil Frequent Itemset FP-Growth

Penerapan *algoritma FP-Growth* menggunakan *minimum support* sebesar 0,01 menghasilkan frequent itemset yang serupa dengan *algoritma Apriori*. *Algoritma FP-Growth* mampu menemukan pola item yang sering muncul tanpa proses candidate generation sehingga lebih efisien dalam proses komputasi. Hasil *frequent itemset FP-Growth* dapat dilihat pada Tabel 5 berikut.

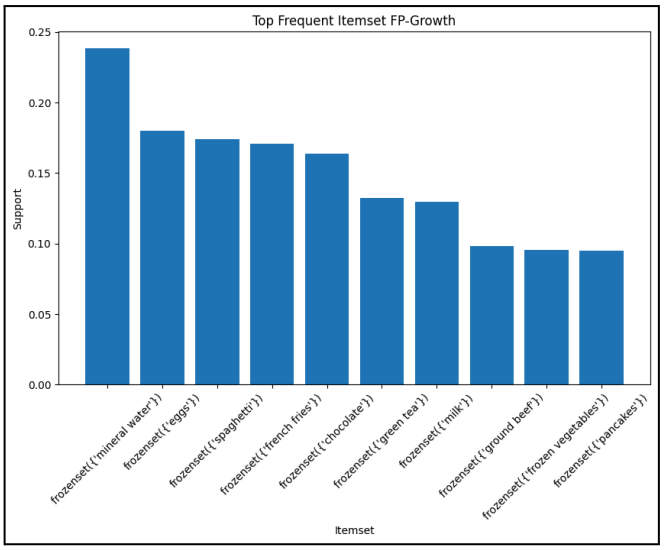
Tabel 5.Top 10 Hasil Frequent Itemset FP-Growth dengan Minimum Support 0,01

No	Support	Itemsets

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

1	0.238368	frozenset({'mineral water'})
2	0.179709	frozenset({'eggs'})
3	0.174110	frozenset({'spaghetti'})
4	0.170911	frozenset({'french fries'})
5	0.163845	frozenset({'chocolate'})
6	0.132116	frozenset({'green tea'})
7	0.129583	frozenset({'milk'})
8	0.098254	frozenset({'ground beef'})
9	0.095321	frozenset({'frozen vegetables'})
10	0.095054	frozenset({'pancakes'})

Berdasarkan Tabel 5, *frequent itemset* yang dihasilkan *FP-Growth* menunjukkan pola pembelian yang sama dengan Apriori, di mana *mineral water* menjadi item dengan frekuensi tertinggi. Kesamaan hasil ini menunjukkan bahwa kedua algoritma mampu menemukan pola asosiasi yang konsisten. Namun, berdasarkan hasil *runtime* pada dataset penelitian ini, *FP-Growth* membutuhkan waktu komputasi lebih lama dibandingkan Apriori.



Gambar 6.Top 10 Frequent Itemset FP-Growth

3.4 Hasil Association Rules

Pada tahap *association rule mining* dilakukan pembentukan aturan asosiasi berdasarkan *frequent itemset* yang telah diperoleh dari *algoritma Apriori* dan *FP-Growth* dengan *minimum support* sebesar 0,01. Selanjutnya dilakukan tuning minimum confidence menggunakan beberapa nilai, yaitu 0,2; 0,3; 0,4; dan 0,5, dengan aturan yang dipilih hanya aturan yang memiliki nilai lift > 1. Karena hasil *association rules* dari *Apriori* dan *FP-Growth* menunjukkan jumlah dan nilai metrik yang sama, maka hasil tuning

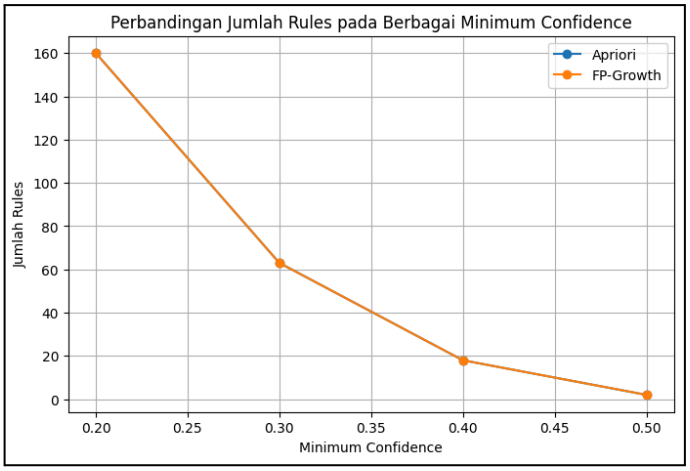
Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

confidence disajikan dalam satu tabel perbandingan berikut.

Tabel 6.Hasil Tuning Minimum Confidence

Minimum Confidence	Apriori Rules	Apriori Avg Confidence	Apriori Avg Lift	FP-Growth Rules	FP-Growth Avg Confidence	FP-Growth Avg Lift
0,2	160	0,289397	1,648743	160	0,289397	1,648743
0,3	63	0,368276	1,774213	63	0,368276	1,774213
0,4	18	0,441415	1,887683	18	0,441415	1,887683
0,5	2	0,504848	2,117935	2	0,504848	2,117935

Berdasarkan Tabel 6, semakin tinggi nilai *minimum confidence* maka jumlah *association rules* yang dihasilkan semakin sedikit. Pada *minimum confidence* 0,2 diperoleh 160 rules, sedangkan pada *minimum confidence* 0,5 hanya diperoleh 2 rules. Nilai *minimum confidence* 0,3 dipilih karena menghasilkan 63 rules dengan *average confidence* sebesar 0,368276 dan *average lift* sebesar 1,774213, sehingga masih memberikan jumlah aturan yang cukup banyak dengan kualitas hubungan antar item yang baik.



Gambar 7. Grafik Perbandingan Jumlah Rules pada Berbagai Minimum Confidence

Berdasarkan Gambar 7, jumlah rules mengalami penurunan signifikan ketika *minimum confidence* dinaikkan. Hal ini menunjukkan bahwa semakin tinggi batas confidence yang digunakan, semakin sedikit aturan yang memenuhi syarat karena hanya aturan dengan tingkat kepercayaan tinggi yang dipertahankan. Pola grafik *Apriori* dan *FP-Growth* terlihat sama karena kedua algoritma menghasilkan association rules yang identik pada dataset dan parameter yang digunakan. Oleh karena itu, *minimum confidence* 0,3 digunakan pada tahap pembentukan aturan asosiasi karena dinilai paling seimbang antara jumlah rules dan kualitas aturan.

Tabel 7.Top 10 Association Rules Berdasarkan Nilai Lift pada Apriori dan FP-Growth

No	Antecedents	Consequents	Support	Confidence	Lift

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

1	herb & pepper	ground beef	0,015998	0,323450	3,291994
2	ground beef, mineral water	spaghetti	0,017064	0,416938	2,394681
3	mineral water, frozen vegetables	milk	0,011065	0,309701	2,389991
4	soup	milk	0,015198	0,300792	2,321232
5	ground beef	spaghetti	0,039195	0,398915	2,291162
6	olive oil, mineral water	spaghetti	0,010265	0,371981	2,136468
7	eggs, ground beef	mineral water	0,010132	0,506667	2,125563
8	milk, ground beef	mineral water	0,011065	0,503030	2,110308
9	red wine	spaghetti	0,010265	0,364929	2,095966
10	olive oil	spaghetti	0,022930	0,348178	1,999758

Berdasarkan Tabel 7, aturan asosiasi terbaik berdasarkan nilai *lift* adalah bahwa konsumen yang membeli *herb & pepper* cenderung juga membeli *ground beef*, dengan nilai *support* sebesar 0,015998, *confidence* sebesar 0,323450, dan *lift* sebesar 3,291994. Nilai *lift* yang lebih dari 1 menunjukkan adanya hubungan positif antara kedua item, sehingga konsumen yang membeli *herb & pepper* memiliki kecenderungan lebih tinggi untuk membeli *ground beef*. Selain itu, beberapa aturan lain seperti konsumen yang membeli *ground beef* dan *mineral water* cenderung juga membeli *spaghetti*, serta konsumen yang membeli *ground beef* cenderung juga membeli *spaghetti*, juga menunjukkan pola pembelian yang kuat. Hasil *association rules* ini dapat dimanfaatkan untuk strategi *bundling* produk, *cross-selling*, dan penataan produk pada sektor *retail*.

3.5 Evaluasi dan Perbandingan Algoritma

Pada tahap evaluasi dilakukan perbandingan performa algoritma Apriori dan FP-Growth berdasarkan jumlah frequent itemset, association rules, nilai confidence, lift, dan waktu komputasi. Hasil pengujian menunjukkan bahwa kedua algoritma menghasilkan frequent itemset dan association rules yang sama pada minimum support 0,01 dan minimum confidence 0,3. Hal ini menunjukkan bahwa Apriori dan FP-Growth mampu menemukan pola asosiasi yang konsisten pada dataset retail.

Tabel 8.Perbandingan Hasil Akhir Algoritma Apriori dan FP-Growth

Metode	Frequent Itemset	Association Rules	Rata-rata Confidence	Rata-rata Lift	Runtime (detik)
Apriori	257	63	0,368276	1,774213	0,438047
FP-Growth	257	63	0,368276	1,774213	4,670108

Berdasarkan Tabel 8, kedua algoritma menghasilkan 257 frequent itemset dan 63 association rules dengan rata-rata lift sebesar 1,774213 yang menunjukkan adanya

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

hubungan positif antar item. Salah satu aturan dengan lift tertinggi adalah hubungan antara *herb & pepper* dan *ground beef* dengan nilai lift sebesar 3,291994, yang menunjukkan bahwa kedua item memiliki kecenderungan dibeli secara bersamaan. Dari sisi runtime, Apriori memiliki waktu komputasi lebih cepat dibandingkan FP-Growth pada dataset penelitian ini, yaitu 0,438047 detik sedangkan FP-Growth membutuhkan 4,670108 detik. Kondisi ini dapat terjadi karena performa algoritma tidak hanya dipengaruhi oleh konsep dasar metode, tetapi juga oleh karakteristik dataset, tingkat kepadatan transaksi, jumlah item unik, serta implementasi algoritma pada library yang digunakan. Pada dataset penelitian ini, ukuran data yang relatif tidak terlalu besar dan struktur transaksi yang cukup jarang menyebabkan proses Apriori dapat berjalan lebih cepat dibandingkan *FP-Growth*, meskipun *FP-Growth* secara teori sering dianggap lebih efisien pada dataset yang besar dan kompleks.

3.6 Pemilihan Metode Terbaik

Berdasarkan hasil evaluasi dan perbandingan algoritma pada sub bab sebelumnya, algoritma Apriori dan FP-Growth menghasilkan jumlah frequent itemset, association rules, nilai confidence, dan nilai lift yang sama pada parameter minimum support 0,01 dan minimum confidence 0,3. Hal ini menunjukkan bahwa kedua algoritma mampu menemukan pola asosiasi yang identik pada dataset *Retail Market Basket Transactions*. Namun, terdapat perbedaan pada efisiensi waktu komputasi, di mana algoritma Apriori memiliki runtime lebih cepat dibandingkan FP-Growth. Oleh karena itu, algoritma Apriori dipilih sebagai metode terbaik pada penelitian ini karena mampu menghasilkan aturan asosiasi yang sama dengan proses komputasi yang lebih efisien.

Selain itu, salah satu aturan asosiasi terbaik menunjukkan bahwa konsumen yang membeli *herb & pepper* cenderung juga membeli *ground beef* dengan nilai confidence sebesar 0,323450 dan lift sebesar 3,291994. Nilai confidence menunjukkan bahwa sekitar 32,3% transaksi yang membeli *herb & pepper* juga membeli *ground beef*, sedangkan nilai lift yang lebih besar dari 1 menunjukkan adanya hubungan asosiasi yang kuat antara kedua item tersebut. Hasil ini dapat dimanfaatkan oleh pihak retail untuk mendukung strategi bisnis seperti product placement, bundling produk, dan rekomendasi produk kepada pelanggan.

3.7 Interpretasi dan Insight Bisnis

Hasil association rule menunjukkan adanya pola pembelian produk yang dapat dimanfaatkan sebagai dasar pengambilan keputusan bisnis pada sektor retail. Pola asosiasi yang terbentuk menunjukkan bahwa beberapa produk memiliki kecenderungan untuk dibeli secara bersamaan dalam satu transaksi. Kondisi tersebut memberikan insight bahwa perilaku pembelian konsumen dapat digunakan untuk menentukan strategi pemasaran yang lebih efektif, baik dalam bentuk bundling produk, cross-selling, maupun penataan produk pada area penjualan. Implementasi insight bisnis berdasarkan hasil association rule ditunjukkan pada Tabel 9.

Tabel 9.Implementasi Insight Bisnis Berdasarkan Association Rules

No	Insight Bisnis	Association Rules	Implementasi
1	Bundling Produk	Konsumen yang membeli *herb & pepper* cenderung juga membeli *ground*	Retail dapat membuat paket promo memasak yang terdiri dari herb & pepper dan ground beef untuk meningkatkan pembelian

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

		beef	produk secara bersamaan.
2	Cross-Selling	Konsumen yang membeli *ground beef* dan *mineral water* cenderung juga membeli *spaghetti*	Sistem rekomendasi dapat menawarkan spaghetti kepada pelanggan yang membeli ground beef dan mineral water.
3	Product Placement	Konsumen yang membeli *olive oil* cenderung juga membeli *spaghetti*	Produk olive oil dan spaghetti dapat ditempatkan pada area rak yang berdekatan agar pelanggan lebih mudah menemukan produk pelengkap.

Berdasarkan Tabel 3.9, hasil association rule dapat membantu pihak retail dalam memahami pola pembelian konsumen secara lebih mendalam. Strategi bundling produk dapat digunakan untuk meningkatkan jumlah pembelian dalam satu transaksi, sedangkan cross-selling dapat membantu menawarkan produk yang relevan kepada pelanggan berdasarkan pola pembelian sebelumnya. Selain itu, penataan produk berdasarkan hubungan asosiasi dapat mempermudah pelanggan dalam menemukan produk pelengkap sehingga pengalaman belanja menjadi lebih efektif dan nyaman.

Hasil penelitian ini menunjukkan bahwa penerapan Frequent Pattern Mining tidak hanya mampu menemukan pola asosiasi antar produk, tetapi juga dapat dimanfaatkan sebagai pendukung pengambilan keputusan bisnis. Dengan memanfaatkan pola pembelian konsumen, pihak retail dapat meningkatkan efektivitas strategi pemasaran sekaligus meningkatkan peluang penjualan produk secara lebih optimal.

BAB 4 Kesimpulan dan Saran

Berdasarkan hasil penelitian, algoritma Apriori dan *FP-Growth* dapat digunakan untuk menganalisis pola pembelian konsumen pada dataset *Retail Market Basket Transactions* melalui metode *Frequent Pattern Mining* dan *association rule mining*. Kedua algoritma menghasilkan jumlah *frequent itemset* dan *association rules* yang sama, yaitu 257 *frequent itemset* dan 63 *association rules* pada minimum *support* sebesar 0,01 dan minimum *confidence* sebesar 0,3. Namun, algoritma Apriori memiliki *runtime* yang lebih cepat dibandingkan *FP-Growth*, sehingga Apriori dipilih sebagai metode terbaik pada dataset penelitian ini. Aturan asosiasi terbaik berdasarkan nilai *lift* menunjukkan bahwa konsumen yang membeli *herb & pepper* cenderung juga membeli *ground beef*, dengan nilai *support* sebesar 0,015998, *confidence* sebesar 0,323450, dan *lift* sebesar 3,291994. Hasil tersebut menunjukkan bahwa penelitian ini berhasil memperoleh *insight* bisnis yang dapat dimanfaatkan untuk strategi *bundling* produk, *cross-selling*, dan penataan produk pada sektor *retail*.

Saran untuk penelitian selanjutnya adalah menggunakan dataset transaksi yang lebih besar, lebih beragam, dan berasal dari transaksi nyata agar pola pembelian yang dihasilkan dapat merepresentasikan perilaku konsumen secara lebih luas. Selain itu, penelitian berikutnya dapat mencoba algoritma lain seperti ECLAT sebagai pembanding tambahan terhadap Apriori dan *FP-Growth*, serta menggunakan data transaksi *real-time* agar hasil analisis lebih relevan dengan kondisi penjualan yang sedang berlangsung. Dengan pengembangan tersebut, hasil analisis pola pembelian diharapkan dapat

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

memberikan manfaat yang lebih optimal dalam mendukung strategi pemasaran, penataan produk, dan peningkatan penjualan pada sektor *retail*.

Daftar Pustaka

Handoko, K., Darmansah, & Adhiatma, N. (2023). Implementasi FP-Growth untuk analisis pola pembelian produk elektronik pada Tokopedia. https://doi.org/10.47709/jpsk.v5i02.6963

Hery, H., & Widjaja, A. E. (2024). Analysis of Apriori and FP-Growth algorithms for market basket insights: A case study of The Bread Basket Bakery sales. https://doi.org/10.47738/jdmdc.v1i1.2

Usmani, S. A., Kamran, S. K., Zeeshan, M., & Islam, N. (2021). A comparative analysis of Apriori and FP-Growth algorithms for frequent pattern mining using Apache Spark. Diakses dari https://www.researchgate.net/publication/352292388_A_Comparative_Analysis_of_Apriori_and_FP-Growth_Algorithms_for_Frequent_Pattern_Mining_Using_Apache_Spark

Rai, V. K., Chakraborty, S., & Chakraborty, S. (2022). Association rule mining for prediction of COVID-19. https://doi.org/10.31181/dmame0317102022r

Xie, H. (2021). Research and case analysis of Apriori algorithm based on mining frequent item-sets. https://doi.org/10.4236/jss.2021.94034

Fabrianto, L., Faizah, N. M., Prasetyo, J. H., Prakoso, B. S., & Wiharso, G. (2021). Aturan asosiasi antar item terjual pada data penjualan minimarket milik komunitas di hari besar tertentu menggunakan algoritma Apriori. https://doi.org/10.30871/jaemb.v9i2.3621

Vivian, Siang, J. J., & Santoso, H. B. (2026). Comparing Apriori and FP-Growth for association rule mining of bakery purchases: A CRISP-DM based approach. https://doi.org/10.31539/qdvqa169

Marshanda, A. P., Al Faroby, M. H. H. Z., & Dzulkarnain, A. (2024). Perbandingan efisiensi metode Apriori dan FP-Growth. *Innovative: Journal of Social Science Research, 4*(4). https://doi.org/10.31004/innovative.v4i4.13972

Lampiran

Lampiran A. Kendala Penelitian

1. Kendala

   Kendala yang dihadapi dalam penelitian ini yaitu pada proses preprocessing data transaksi retail yang memiliki banyak missing value dan transaksi duplikat sehingga diperlukan penyesuaian agar data tetap valid untuk proses Market Basket Analysis. Selain itu, penentuan nilai minimum support dan minimum confidence juga menjadi tantangan karena sangat mempengaruhi jumlah frequent itemset, association rules, serta waktu komputasi algoritma. Pada proses evaluasi, hasil penelitian menunjukkan bahwa runtime algoritma FP-Growth pada dataset penelitian ini lebih lambat dibandingkan algoritma Apriori sehingga diperlukan analisis lebih lanjut terhadap karakteristik dataset yang digunakan.

2. Solusi

   Solusi yang dilakukan dalam penelitian ini yaitu dengan mempertahankan missing value dan transaksi duplikat yang masih valid karena tetap merepresentasikan perilaku pembelian konsumen pada Market Basket Analysis.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Selain itu, dilakukan proses preprocessing dan transformasi data secara bertahap agar dataset dapat diproses dengan baik oleh algoritma Apriori dan FP-Growth. Peneliti juga melakukan tuning minimum support dan minimum confidence untuk menentukan parameter yang menghasilkan association rules yang optimal dengan runtime yang lebih efisien. Selanjutnya, dilakukan evaluasi dan perbandingan kedua algoritma untuk mengetahui metode yang paling sesuai dengan karakteristik dataset penelitian.

Lampiran B. Kontribusi Setiap Anggota Kelompok

Nama	NIM	Kontribusi
Adisti Eka Nabila	24031554119	Berkontribusi dalam penyusunan BAB 4 Kesimpulan dan Saran, revisi bagian 2.5 *Exploratory Data Analysis* (EDA) dan 2.8 *Frequent Pattern Mining*, serta penyusunan bagian 2.15 Analisis dan Interpretasi Hasil, 3.3 Hasil *Frequent Pattern Mining*, dan 3.4 Hasil *Association Rule*. Selain itu, turut memastikan bagian 2.2 Variabel Penelitian dan 2.12 Metrik Evaluasi tetap sesuai dengan metodologi penelitian. Kontribusi lainnya juga mencakup penyusunan *coding* untuk proses analisis penelitian.
Umi Imro'atus Sholekhah	24031554150	Berkontribusi dalam penyusunan dan revisi BAB 1 Pendahuluan, revisi bagian 2.9 Algoritma Apriori dan 2.10 Algoritma *FP-Growth* dengan penambahan analisis *runtime*, serta penyusunan bagian 2.13 Evaluasi dan Perbandingan Algoritma, 3.5 Evaluasi dan Perbandingan Algoritma, 3.6 Pemilihan Metode Terbaik, dan 3.7 Interpretasi *Insight* Bisnis. Selain itu, turut memastikan bagian 2.4 Tahapan Penelitian tetap sesuai dengan alur

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

		penelitian. Kontribusi lainnya juga mencakup penyusunan *coding* untuk proses analisis penelitian.
Maris Al Sabina Azzuhra	24031554188	Berkontribusi dalam penyusunan bagian 3.1 Karakteristik Data dan 3.2 Hasil *Preprocessing*, revisi bagian 2.6 *Preprocessing Data*, serta memastikan bagian 2.7 Transformasi Data tetap sesuai dengan kebutuhan penelitian. Selain itu, turut menyusun bagian 2.11 *Association Rule* dan 2.14 Pemilihan Metode Terbaik, serta memastikan bagian 2.1 Penjelasan Dataset dan 2.3 Penelitian Terdahulu tetap relevan dengan topik penelitian. Kontribusi lainnya juga mencakup penyusunan *coding* untuk proses analisis penelitian.